Sinh văn bản tăng cường truy xuất cho các tác vụ NLP đòi hỏi nhiều tri thức

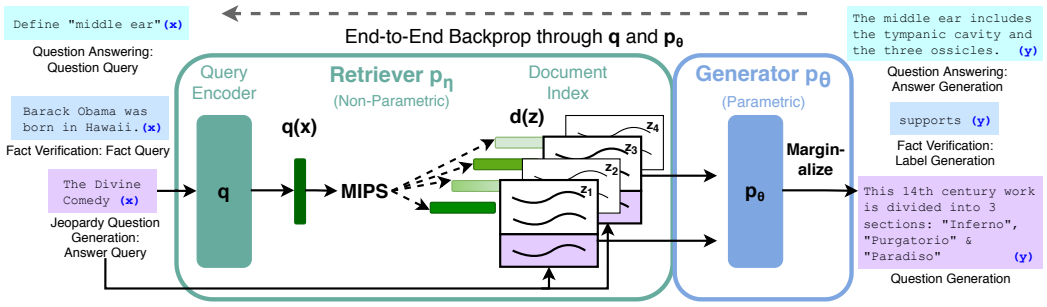
(Bản dịch tiếng Việt của: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks)

Patrick Lewis[†‡], **Ethan Perez**[⋆],
Aleksandra Piktus[†], **Fabio Petroni**[†], **Vladimir Karpukhin**[†], **Naman Goyal**[†], **Heinrich Küttler**[†],
Mike Lewis[†], **Wen-tau Yih**[†], **Tim Rocktäschel**[†‡], **Sebastian Riedel**[†‡], **Douwe Kiela**[†]
[†]Facebook AI Research; [‡]University College London; [⋆]New York University;
plewis@fb.com

Tóm tắt

Các mô hình ngôn ngữ lớn được huấn luyện trước đã được chứng minh là lưu trữ tri thức thực tế (factual knowledge) trong các tham số của chúng, và đạt được kết quả tiên tiến nhất (state-of-the-art) khi được tinh chỉnh trên các tác vụ NLP hạ nguồn. Tuy nhiên, khả năng truy cập và thao tác chính xác tri thức của chúng vẫn còn hạn chế, và do đó trên các tác vụ đòi hỏi nhiều tri thức, hiệu năng của chúng vẫn tụt hậu so với các kiến trúc chuyên biệt cho từng tác vụ. Ngoài ra, việc cung cấp nguồn gốc (provenance) cho các quyết định của chúng và cập nhật tri thức về thế giới của chúng vẫn là những bài toán nghiên cứu còn bỏ ngỏ. Các mô hình được huấn luyện trước có cơ chế truy cập khả vi tới bộ nhớ phi tham số tường minh cho đến nay mới chỉ được nghiên cứu cho các tác vụ hạ nguồn dạng trích xuất. Chúng tôi khám phá một công thức tinh chỉnh đa dụng cho *sinh văn bản tăng cường truy xuất* (retrieval-augmented generation – RAG) — các mô hình kết hợp bộ nhớ tham số và bộ nhớ phi tham số đã được huấn luyện trước để sinh ngôn ngữ. Chúng tôi giới thiệu các mô hình RAG trong đó bộ nhớ tham số là một mô hình seq2seq được huấn luyện trước và bộ nhớ phi tham số là một chỉ mục vectơ dày đặc (dense vector index) của Wikipedia, được truy cập bằng một bộ truy xuất nơ-ron được huấn luyện trước. Chúng tôi so sánh hai cách công thức hoá RAG: một cách điều kiện hoá trên cùng các đoạn văn được truy xuất cho toàn bộ chuỗi được sinh, và cách còn lại có thể sử dụng các đoạn văn khác nhau cho mỗi token. Chúng tôi tinh chỉnh và đánh giá các mô hình của mình trên nhiều tác vụ NLP đòi hỏi nhiều tri thức và thiết lập kết quả tiên tiến nhất trên ba tác vụ hỏi đáp miền mở, vượt trội các mô hình seq2seq tham số và các kiến trúc truy xuất-rồi-trích xuất chuyên biệt cho tác vụ. Với các tác vụ sinh ngôn ngữ, chúng tôi nhận thấy các mô hình RAG sinh ra ngôn ngữ cụ thể hơn, đa dạng hơn và đúng sự thật hơn so với một mô hình cơ sở seq2seq thuần tham số tiên tiến nhất.

Ghi chú của người dịch: Đây là bản dịch tiếng Việt đầy đủ của bài báo arXiv:2005.11401v4 [cs.CL] (12/4/2021), công bố tại NeurIPS 2020. Các hình được giữ nguyên từ bản gốc (nhãn trong hình bằng tiếng Anh); toàn bộ văn bản, chú thích hình và bảng được dịch. Tên mô hình, tên tập dữ liệu và danh mục tài liệu tham khảo được giữ nguyên. Một số thuật ngữ được kèm tiếng Anh trong ngoặc; bảng đối chiếu thuật ngữ ở cuối tài liệu. Các ghi chú của người dịch được đánh số la mã (i, ii, …) để phân biệt với chú thích của tác giả.



Hình 1: Tổng quan về phương pháp của chúng tôi. Chúng tôi kết hợp một bộ truy xuất được huấn luyện trước (*Bộ mã hoá truy vấn + Chỉ mục tài liệu*) với một mô hình seq2seq được huấn luyện trước (*Bộ sinh*) và tinh chỉnh đầu-cuối (end-to-end). Với truy vấn x, chúng tôi sử dụng Tìm kiếm Tích vô hướng Cực đại (Maximum Inner Product Search – MIPS) để tìm top-K tài liệu z_i. Để đưa ra dự đoán cuối cùng y, chúng tôi xem z như một biến ẩn và lấy biên (marginalize) trên các dự đoán seq2seq ứng với các tài liệu khác nhau.

1 Giới thiệu

Các mô hình ngôn ngữ nơ-ron được huấn luyện trước đã được chứng minh là học được một lượng đáng kể tri thức chuyên sâu từ dữ liệu [47]. Chúng có thể làm được điều này mà không cần truy cập bất kỳ bộ nhớ ngoài nào, như một cơ sở tri thức ngầm được tham số hoá [51, 52]. Mặc dù bước phát triển này rất thú vị, các mô hình như vậy vẫn có những nhược điểm: chúng không thể dễ dàng mở rộng hay sửa đổi bộ nhớ của mình, không thể trực tiếp cung cấp cái nhìn sâu sắc về các dự đoán của mình, và có thể tạo ra "ảo giác" (hallucination) [38]. Các mô hình lai kết hợp bộ nhớ tham số với bộ nhớ phi tham số (tức là dựa trên truy xuất) [20, 26, 48] có thể giải quyết một số vấn đề này vì tri thức có thể được sửa đổi và mở rộng trực tiếp, và tri thức được truy cập có thể được kiểm tra và diễn giải. REALM [20] và ORQA [31], hai mô hình được giới thiệu gần đây kết hợp mô hình ngôn ngữ che mặt nạ (masked language model) [8] với một bộ truy xuất khả vi, đã cho thấy những kết quả đầy hứa hẹn,

nhưng mới chỉ khám phá bài toán hỏi đáp trích xuất miền mở. Ở đây, chúng tôi đưa bộ nhớ lai tham số và phi tham số vào "con ngựa thồ của NLP", tức là các mô hình chuỗi-sang-chuỗi (sequence-to-sequence, seq2seq).

Chúng tôi trang bị cho các mô hình sinh có bộ nhớ tham số đã được huấn luyện trước một bộ nhớ phi tham số thông qua một phương pháp tinh chỉnh đa dụng mà chúng tôi gọi là sinh văn bản tăng cường truy xuất (RAG). Chúng tôi xây dựng các mô hình RAG trong đó bộ nhớ tham số là một transformer seq2seq được huấn luyện trước, và bộ nhớ phi tham số là một chỉ mục vectơ dày đặc của Wikipedia, được truy cập bằng một bộ truy xuất nơ-ron được huấn luyện trước. Chúng tôi kết hợp các thành phần này trong một mô hình xác suất được huấn luyện đầu-cuối (Hình 1). Bộ truy xuất (Dense Passage Retriever [26], từ đây gọi là DPR) cung cấp các tài liệu ẩn được điều kiện hoá theo đầu vào, và mô hình seq2seq (BART [32]) sau đó điều kiện hoá trên các tài liệu ẩn này cùng với đầu vào để sinh ra đầu ra. Chúng tôi lấy biên các tài liệu ẩn bằng một phép xấp xỉ top-K, hoặc theo từng đầu ra (giả định rằng cùng một tài liệu chịu trách nhiệm cho tất cả các token) hoặc theo từng token (trong đó các tài liệu khác nhau chịu trách nhiệm cho các token khác nhau). Giống như T5 [51] hoặc BART, RAG có thể được tinh chỉnh trên bất kỳ tác vụ seq2seq nào, trong đó cả bộ sinh và bộ truy xuất đều được học đồng thời.

Đã có nhiều công trình trước đây đề xuất các kiến trúc để làm giàu hệ thống bằng bộ nhớ phi tham số, được huấn luyện từ đầu cho các tác vụ cụ thể, ví dụ như mạng bộ nhớ (memory networks) [64, 55], mạng tăng cường ngăn xếp (stack-augmented networks) [25] và tầng bộ nhớ (memory layers) [30]. Ngược lại, chúng tôi khám phá một bối cảnh trong đó cả hai thành phần bộ nhớ tham số và phi tham số đều được huấn luyện trước và được nạp sẵn tri thức phong phú. Điều quan trọng là, nhờ sử dụng

các cơ chế truy cập đã được huấn luyện trước, khả năng truy cập tri thức đã có sẵn mà không cần huấn luyện thêm.

Các kết quả của chúng tôi làm nổi bật lợi ích của việc kết hợp bộ nhớ tham số và phi tham số với quá trình sinh cho các *tác vụ đòi hỏi nhiều tri thức* (knowledge-intensive tasks) — những tác vụ mà con người khó có thể được kỳ vọng thực hiện một cách hợp lý nếu không được tiếp cận một nguồn tri thức bên ngoài. Các mô hình RAG của chúng tôi đạt kết quả tiên tiến nhất trên Natural Questions mở [29], WebQuestions [3] và CuratedTrec [2], và vượt trội rõ rệt so với các phương pháp gần đây sử dụng các mục tiêu huấn luyện trước chuyên biệt trên TriviaQA [24]. Mặc dù đây là các tác vụ trích xuất, chúng tôi nhận thấy rằng việc sinh không ràng buộc vượt trội các phương pháp trích xuất trước đây. Đối với sinh văn bản đòi hỏi nhiều tri thức, chúng tôi thử nghiệm với MS-MARCO [1] và sinh câu hỏi Jeopardy, và nhận thấy rằng các mô hình của chúng tôi sinh ra các câu trả lời đúng sự thật hơn, cụ thể hơn và đa dạng hơn so với mô hình cơ sở BART. Đối với kiểm chứng sự thật FEVER [56], chúng tôi đạt kết quả chỉ kém 4.3% so với các mô hình pipeline tiên tiến nhất vốn sử dụng giám sát truy xuất mạnh. Cuối cùng, chúng tôi chứng minh rằng bộ nhớ phi tham số có thể được thay thế để cập nhật tri thức của mô hình khi thế giới thay đổi.[1]

2 Phương pháp

Chúng tôi khám phá các mô hình RAG, sử dụng chuỗi đầu vào x để truy xuất các tài liệu văn bản z và dùng chúng làm ngữ cảnh bổ sung khi sinh chuỗi đích y. Như thể hiện trong Hình 1, các mô hình của chúng tôi tận dụng hai thành phần: (i) một bộ truy xuất $p_\eta(z|x)$ với các tham số η, trả về các phân phối (được cắt ngắn top-K) trên các đoạn văn bản khi cho một truy vấn x, và (ii) một bộ sinh $p_\theta(y_i|x, z, y_{1:i-1})$ được tham số hoá bởi θ, sinh ra token hiện tại dựa trên ngữ cảnh gồm $i-1$ token trước đó $y_{1:i-1}$, đầu vào gốc x và một đoạn văn được truy xuất z.

Để huấn luyện bộ truy xuất và bộ sinh theo kiểu đầu-cuối, chúng tôi xem tài liệu được truy xuất như một biến ẩn. Chúng tôi đề xuất hai mô hình lấy biên trên các tài liệu ẩn theo những cách khác nhau để tạo ra một phân phối trên văn bản được sinh. Trong cách tiếp cận thứ nhất, *RAG-Sequence*, mô hình sử dụng cùng một tài liệu để dự đoán mỗi token đích. Cách tiếp cận thứ hai, *RAG-Token*, có thể dự đoán mỗi token đích dựa trên một tài liệu khác nhau. Trong phần tiếp theo, chúng tôi giới thiệu chính thức cả hai mô hình, sau đó mô tả các thành phần p_η và p_θ, cũng như quy trình huấn luyện và giải mã.

2.1 Các mô hình

Mô hình RAG-Sequence Mô hình RAG-Sequence sử dụng cùng một tài liệu được truy xuất để sinh toàn bộ chuỗi. Về mặt kỹ thuật, nó xem tài liệu được truy xuất như một biến ẩn duy nhất, được lấy biên để thu được xác suất seq2seq $p(y|x)$ thông qua một phép xấp xỉ top-K. Cụ thể, top K tài liệu được truy xuất bằng bộ truy xuất, và bộ sinh tính xác suất của chuỗi đầu ra cho mỗi tài liệu; sau đó các xác suất này được lấy biên,

$$p_{\text{RAG-Sequence}}(y|x) \approx \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x)\, p_\theta(y|x,z) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) \prod_i^N p_\theta(y_i|x, z, y_{1:i-1})$$

Mô hình RAG-Token Trong mô hình RAG-Token, chúng ta có thể rút ra một tài liệu ẩn khác nhau cho mỗi token đích và lấy biên tương ứng. Điều này cho phép bộ sinh chọn nội dung từ nhiều tài liệu khi tạo ra câu trả lời. Cụ thể, top K tài liệu được truy xuất bằng bộ truy xuất, sau đó bộ sinh tạo ra một phân phối cho token đầu ra tiếp theo ứng với mỗi tài liệu, trước khi lấy biên, rồi lặp lại quá trình

[1] Mã nguồn để chạy các thí nghiệm với RAG đã được công bố mã nguồn mở như một phần của thư viện HuggingFace Transformers [66] và có thể tìm thấy tại `https://github.com/huggingface/transformers/blob/master/examples/rag/`. Bản demo tương tác của các mô hình RAG có thể được tìm thấy tại `https://huggingface.co/rag/`

với token đầu ra kế tiếp. Một cách hình thức, chúng tôi định nghĩa:

$$p_{\text{RAG-Token}}(y|x) \approx \prod_{i}^{N} \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x)\, p_\theta(y_i|x, z, y_{1:i-1})$$

Cuối cùng, chúng tôi lưu ý rằng RAG có thể được dùng cho các tác vụ phân loại chuỗi bằng cách xem lớp đích như một chuỗi đích có độ dài bằng một; khi đó RAG-Sequence và RAG-Token là tương đương.

2.2 Bộ truy xuất: DPR

Thành phần truy xuất $p_\eta(z|x)$ dựa trên DPR [26]. DPR tuân theo kiến trúc bộ mã hoá kép (bi-encoder):

$$p_\eta(z|x) \propto \exp\big(\mathbf{d}(z)^\top \mathbf{q}(x)\big) \qquad \mathbf{d}(z) = \text{BERT}_d(z), \quad \mathbf{q}(x) = \text{BERT}_q(x)$$

trong đó $\mathbf{d}(z)$ là biểu diễn dày đặc của một tài liệu do bộ mã hoá tài liệu $\text{BERT}_{\text{BASE}}$ [8] tạo ra, và $\mathbf{q}(x)$ là biểu diễn truy vấn do một bộ mã hoá truy vấn, cũng dựa trên $\text{BERT}_{\text{BASE}}$, tạo ra. Việc tính top-$k(p_\eta(\cdot|x))$, danh sách k tài liệu z có xác suất tiên nghiệm $p_\eta(z|x)$ cao nhất, là một bài toán Tìm kiếm Tích vô hướng Cực đại (MIPS), có thể được giải xấp xỉ trong thời gian dưới tuyến tính [23]. Chúng tôi sử dụng một bi-encoder đã được huấn luyện trước từ DPR để khởi tạo bộ truy xuất và xây dựng chỉ mục tài liệu. Bộ truy xuất này đã được huấn luyện để truy xuất các tài liệu chứa câu trả lời cho các câu hỏi của TriviaQA [24] và Natural Questions [29]. Chúng tôi gọi chỉ mục tài liệu là *bộ nhớ phi tham số*.

2.3 Bộ sinh: BART

Thành phần sinh $p_\theta(y_i|x, z, y_{1:i-1})$ có thể được mô hình hoá bằng bất kỳ kiến trúc mã hoá–giải mã (encoder-decoder) nào. Chúng tôi sử dụng BART-large [32], một transformer seq2seq [58] được huấn luyện trước với 400 triệu tham số. Để kết hợp đầu vào x với nội dung được truy xuất z khi sinh bằng BART, chúng tôi chỉ đơn giản nối (concatenate) chúng lại với nhau. BART được huấn luyện trước bằng một mục tiêu khử nhiễu (denoising) với nhiều hàm gây nhiễu khác nhau. Nó đã đạt kết quả tiên tiến nhất trên nhiều tác vụ sinh đa dạng và vượt trội các mô hình T5 có kích thước tương đương [32]. Từ đây, chúng tôi gọi các tham số θ của bộ sinh BART là *bộ nhớ tham số*.

2.4 Huấn luyện

Chúng tôi huấn luyện đồng thời các thành phần truy xuất và sinh mà không có bất kỳ giám sát trực tiếp nào về việc tài liệu nào nên được truy xuất. Cho một tập dữ liệu huấn luyện tinh chỉnh gồm các cặp đầu vào/đầu ra (x_j, y_j), chúng tôi cực tiểu hoá log-hợp lý biên âm (negative marginal log-likelihood) của mỗi đích, $\sum_j -\log p(y_j|x_j)$, bằng phương pháp hạ gradient ngẫu nhiên với Adam [28]. Việc cập nhật bộ mã hoá tài liệu BERT_d trong quá trình huấn luyện rất tốn kém vì nó đòi hỏi chỉ mục tài liệu phải được cập nhật định kỳ, như REALM đã làm trong giai đoạn huấn luyện trước [20]. Chúng tôi nhận thấy bước này không cần thiết để đạt hiệu năng cao, và giữ cố định bộ mã hoá tài liệu (cùng chỉ mục), chỉ tinh chỉnh bộ mã hoá truy vấn BERT_q và bộ sinh BART.

2.5 Giải mã

Tại thời điểm kiểm thử, RAG-Sequence và RAG-Token đòi hỏi những cách khác nhau để xấp xỉ $\arg\max_y p(y|x)$.

RAG-Token Mô hình RAG-Token có thể được xem như một bộ sinh seq2seq tự hồi quy (autoregressive) tiêu chuẩn với xác suất chuyển tiếp:

$$p'_\theta(y_i|x, y_{1:i-1}) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z_i|x)\, p_\theta(y_i|x, z_i, y_{1:i-1})$$

Để giải mã, chúng ta có thể đưa $p'_\theta(y_i|x, y_{1:i-1})$ vào một bộ giải mã tìm kiếm chùm (beam search) tiêu chuẩn.

RAG-Sequence Với RAG-Sequence, hàm hợp lý $p(y|x)$ không tách được thành hợp lý theo từng token thông thường, do đó ta không thể giải nó bằng một lần tìm kiếm chùm duy nhất. Thay vào đó, chúng tôi chạy tìm kiếm chùm cho mỗi tài liệu z, chấm điểm mỗi giả thuyết bằng $p_\theta(y_i|x, z, y_{1:i-1})$. Điều này tạo ra một tập giả thuyết Y, trong đó một số giả thuyết có thể không xuất hiện trong chùm của tất cả các tài liệu. Để ước lượng xác suất của một giả thuyết y, chúng tôi chạy thêm một lượt truyền xuôi (forward pass) cho mỗi tài liệu z mà y không xuất hiện trong chùm, nhân xác suất của bộ sinh với $p_\eta(z|x)$, rồi cộng các xác suất qua các chùm để có xác suất biên. Chúng tôi gọi quy trình giải mã này là "Giải mã Kỹ lưỡng" (Thorough Decoding). Với các chuỗi đầu ra dài hơn, $|Y|$ có thể trở nên lớn, đòi hỏi nhiều lượt truyền xuôi. Để giải mã hiệu quả hơn, chúng tôi có thể thực hiện thêm một phép xấp xỉ rằng $p_\theta(y|x, z_i) \approx 0$ khi y không được sinh ra trong quá trình tìm kiếm chùm từ x, z_i. Điều này giúp tránh phải chạy thêm các lượt truyền xuôi sau khi tập ứng viên Y đã được sinh ra. Chúng tôi gọi quy trình giải mã này là "Giải mã Nhanh" (Fast Decoding).

3 Thí nghiệm

Chúng tôi thử nghiệm RAG trên nhiều tác vụ đòi hỏi nhiều tri thức. Trong tất cả các thí nghiệm, chúng tôi sử dụng một bản kết xuất (dump) Wikipedia duy nhất làm nguồn tri thức phi tham số. Theo Lee và cộng sự [31] và Karpukhin và cộng sự [26], chúng tôi sử dụng bản kết xuất tháng 12 năm 2018. Mỗi bài viết Wikipedia được chia thành các đoạn 100 từ không chồng lấn, tạo thành tổng cộng 21 triệu tài liệu. Chúng tôi sử dụng bộ mã hoá tài liệu để tính vectơ nhúng (embedding) cho mỗi tài liệu, và xây dựng một chỉ mục MIPS duy nhất bằng FAISS [23] với phép xấp xỉ Hierarchical Navigable Small World để truy xuất nhanh [37]. Trong quá trình huấn luyện, chúng tôi truy xuất top k tài liệu cho mỗi truy vấn. Chúng tôi xét $k \in \{5, 10\}$ khi huấn luyện và chọn k cho thời điểm kiểm thử dựa trên dữ liệu phát triển (dev). Tiếp theo, chúng tôi trình bày chi tiết thí nghiệm cho từng tác vụ.

3.1 Hỏi đáp miền mở

Hỏi đáp (QA) miền mở là một ứng dụng thực tế quan trọng và là môi trường thử nghiệm phổ biến cho các tác vụ đòi hỏi nhiều tri thức [20]. Chúng tôi xem câu hỏi và câu trả lời như các cặp văn bản đầu vào–đầu ra (x, y) và huấn luyện RAG bằng cách trực tiếp cực tiểu hoá log-hợp lý âm của câu trả lời. Chúng tôi so sánh RAG với mô hình QA trích xuất phổ biến [5, 7, 31, 26], trong đó câu trả lời là các đoạn (span) được trích ra từ tài liệu được truy xuất, chủ yếu dựa vào tri thức phi tham số. Chúng tôi cũng so sánh với các phương pháp "QA sách đóng" (Closed-Book QA) [52], vốn giống RAG ở chỗ sinh câu trả lời, nhưng không khai thác truy xuất mà hoàn toàn dựa vào tri thức tham số. Chúng tôi xét bốn tập dữ liệu QA miền mở phổ biến: Natural Questions (NQ) [29], TriviaQA (TQA) [24], WebQuestions (WQ) [3] và CuratedTrec (CT) [2]. Vì CT và WQ có kích thước nhỏ, chúng tôi làm theo DPR [26] bằng cách khởi tạo các mô hình CT và WQ từ mô hình RAG đã huấn luyện trên NQ. Chúng tôi sử dụng cùng cách chia train/dev/test như các công trình trước [31, 26] và báo cáo điểm Khớp Chính xác (Exact Match – EM). Với TQA, để so sánh với T5 [52], chúng tôi cũng đánh giá trên tập kiểm thử TQA Wiki.

3.2 Hỏi đáp trừu tượng

Các mô hình RAG có thể vượt ra ngoài QA trích xuất đơn giản và trả lời câu hỏi bằng văn bản sinh tự do, mang tính trừu tượng (abstractive). Để kiểm tra khả năng sinh ngôn ngữ tự nhiên (NLG) của RAG trong bối cảnh đòi hỏi nhiều tri thức, chúng tôi sử dụng tác vụ MSMARCO NLG v2.1 [43]. Tác vụ này bao gồm các câu hỏi, mười đoạn văn chuẩn (gold) được truy xuất từ một công cụ tìm kiếm cho mỗi câu hỏi, và một câu trả lời dạng câu hoàn chỉnh được chú thích từ các đoạn văn được truy xuất. Chúng tôi không sử dụng các đoạn văn được cung cấp, chỉ sử dụng câu hỏi và câu trả lời, để

xem MSMARCO như một tác vụ QA trừu tượng miền mở. MSMARCO có một số câu hỏi không thể trả lời sao cho khớp với câu trả lời tham chiếu nếu không có quyền truy cập vào các đoạn văn chuẩn, chẳng hạn như "What is the weather in Volcano, CA?" ("Thời tiết ở Volcano, CA thế nào?"), vì vậy hiệu năng sẽ thấp hơn khi không sử dụng các đoạn văn chuẩn. Chúng tôi cũng lưu ý rằng một số câu hỏi MSMARCO không thể trả lời chỉ bằng Wikipedia. Khi đó, RAG có thể dựa vào tri thức tham số để sinh ra những câu trả lời hợp lý.

3.3 Sinh câu hỏi Jeopardy

Để đánh giá khả năng sinh của RAG trong bối cảnh không phải QA, chúng tôi nghiên cứu bài toán sinh câu hỏi miền mở. Thay vì sử dụng câu hỏi từ các tác vụ QA miền mở tiêu chuẩn, vốn thường gồm những câu hỏi ngắn và đơn giản, chúng tôi đề xuất tác vụ khó hơn là sinh câu hỏi Jeopardy. Jeopardy là một định dạng khác thường, trong đó người chơi phải cố gắng đoán một thực thể từ một sự kiện (fact) về thực thể đó. Ví dụ, "The World Cup" là câu trả lời cho câu hỏi "In 1986 Mexico scored as the first country to host this international sports competition twice." ("Năm 1986, Mexico ghi dấu là quốc gia đầu tiên hai lần đăng cai giải đấu thể thao quốc tế này."). Vì các câu hỏi Jeopardy là những phát biểu chính xác, mang tính sự thật, việc sinh câu hỏi Jeopardy khi được điều kiện hoá trên thực thể trả lời của chúng tạo thành một tác vụ sinh đòi hỏi nhiều tri thức đầy thách thức.

Chúng tôi sử dụng cách chia dữ liệu từ SearchQA [10], với 100 nghìn mẫu huấn luyện, 14 nghìn mẫu phát triển và 27 nghìn mẫu kiểm thử. Vì đây là một tác vụ mới, chúng tôi huấn luyện một mô hình BART để so sánh. Theo [67], chúng tôi đánh giá bằng thước đo Q-BLEU-1 được tinh chỉnh trên SQuAD [42]. Q-BLEU là một biến thể của BLEU với trọng số cao hơn cho việc khớp các thực thể, và có tương quan với đánh giá của con người cao hơn so với các thước đo tiêu chuẩn đối với bài toán sinh câu hỏi. Chúng tôi cũng thực hiện hai đánh giá của con người, một để đánh giá tính xác thực của văn bản sinh, và một cho tính cụ thể. Chúng tôi định nghĩa *tính xác thực* (factuality) là việc một phát biểu có thể được chứng thực bởi các nguồn bên ngoài đáng tin cậy hay không, và *tính cụ thể* (specificity) là mức độ phụ thuộc lẫn nhau cao giữa đầu vào và đầu ra [33]. Chúng tôi tuân theo thực hành tốt nhất và sử dụng đánh giá so sánh theo cặp [34]. Người đánh giá được cho xem một câu trả lời và hai câu hỏi được sinh ra, một từ BART và một từ RAG. Sau đó họ được yêu cầu chọn một trong bốn lựa chọn — câu hỏi A tốt hơn, câu hỏi B tốt hơn, cả hai đều tốt, hoặc không câu nào tốt.

3.4 Kiểm chứng sự thật

FEVER [56] yêu cầu phân loại xem một khẳng định (claim) bằng ngôn ngữ tự nhiên được Wikipedia ủng hộ hay bác bỏ, hoặc liệu có không đủ thông tin để quyết định. Tác vụ này đòi hỏi truy xuất bằng chứng từ Wikipedia liên quan đến khẳng định, sau đó suy luận trên bằng chứng này để phân loại khẳng định là đúng, sai, hay không thể kiểm chứng chỉ từ Wikipedia. FEVER là một bài toán truy xuất gắn liền với một tác vụ suy luận kéo theo (entailment) đầy thách thức. Nó cũng là một môi trường thử nghiệm phù hợp để khám phá khả năng của các mô hình RAG trong việc xử lý bài toán phân loại thay vì sinh. Chúng tôi ánh xạ các nhãn lớp của FEVER (ủng hộ, bác bỏ, hoặc không đủ thông tin) thành các token đầu ra đơn lẻ và huấn luyện trực tiếp với các cặp khẳng định–lớp. Điều quan trọng là, không giống hầu hết các phương pháp khác cho FEVER, chúng tôi không sử dụng giám sát trên bằng chứng được truy xuất. Trong nhiều ứng dụng thực tế, tín hiệu giám sát truy xuất không có sẵn, và các mô hình không đòi hỏi sự giám sát như vậy sẽ áp dụng được cho phạm vi tác vụ rộng hơn. Chúng tôi khám phá hai biến thể: tác vụ phân loại 3 lớp tiêu chuẩn (ủng hộ/bác bỏ/không đủ thông tin) và tác vụ 2 lớp (ủng hộ/bác bỏ) được nghiên cứu trong Thorne và Vlachos [57]. Trong cả hai trường hợp, chúng tôi báo cáo độ chính xác nhãn.

Bảng 1: Điểm kiểm thử QA miền mở. Với TQA, cột bên trái sử dụng tập kiểm thử tiêu chuẩn cho QA miền mở, cột bên phải sử dụng tập kiểm thử TQA-Wiki. Xem Phụ lục D để biết thêm chi tiết.

	Mô hình	NQ	TQA	WQ	CT
Sách đóng	T5-11B [52]	34.5	-/50.1	37.4	-
	T5-11B+SSM[52]	36.6	-/60.5	44.7	-
Sách mở	REALM [20]	40.4	-/-	40.7	46.8
	DPR [26]	41.5	**57.9**/-	41.1	50.6
	RAG-Token	44.1	55.2/66.1	**45.5**	50.0
	RAG-Seq.	**44.5**	56.8/**68.0**	45.2	**52.2**

Bảng 2: Điểm kiểm thử cho các tác vụ sinh và phân loại. SotA của MS-MARCO là [4], FEVER-3 là [68] và FEVER-2 là [57]. *Sử dụng ngữ cảnh/bằng chứng chuẩn (gold). Mô hình tốt nhất không truy cập dữ liệu chuẩn được gạch chân.

Mô hình	Jeopardy B-1	Jeopardy QB-1	MSMARCO R-L	MSMARCO B-1	FVR3 Đ.c.x. nhãn	FVR2 Đ.c.x. nhãn
SotA	-	-	**49.8***	**49.9***	**76.8**	**92.2***
BART	15.1	19.7	38.2	41.6	64.0	81.1
RAG-Tok.	**17.3**	**22.2**	40.1	41.5	72.5	89.5
RAG-Seq.	14.7	21.4	40.8	44.2		

(Đ.c.x. nhãn = độ chính xác nhãn)

4 Kết quả

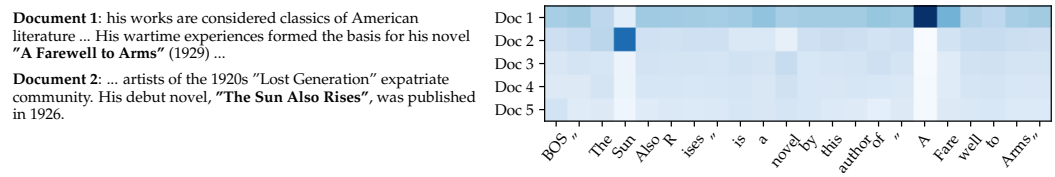
4.1 Hỏi đáp miền mở

Bảng 1 trình bày kết quả của RAG cùng với các mô hình tiên tiến nhất. Trên cả bốn tác vụ QA miền mở, RAG thiết lập một kết quả tiên tiến nhất mới (với TQA thì chỉ trên tập chia có thể so sánh với T5). RAG kết hợp sự linh hoạt trong việc sinh của các phương pháp "sách đóng" (chỉ tham số) với hiệu năng của các phương pháp "sách mở" dựa trên truy xuất. Không giống REALM và T5+SSM, RAG đạt kết quả mạnh mà không cần giai đoạn huấn luyện trước "che mặt nạ các đoạn nổi bật" (salient span masking) tốn kém và chuyên biệt [20]. Đáng chú ý là bộ truy xuất của RAG được khởi tạo từ bộ truy xuất của DPR, vốn sử dụng giám sát truy xuất trên Natural Questions và TriviaQA. RAG cho kết quả tốt hơn so với hệ thống QA của DPR, vốn sử dụng một "bộ mã hoá chéo" (cross-encoder) dựa trên BERT để xếp hạng lại tài liệu, cùng với một bộ đọc trích xuất (extractive reader). RAG chứng minh rằng cả bộ xếp hạng lại (re-ranker) lẫn bộ đọc trích xuất đều không cần thiết để đạt hiệu năng tiên tiến nhất.

Có nhiều lợi thế khi sinh câu trả lời ngay cả khi có thể trích xuất chúng. Những tài liệu chứa manh mối về câu trả lời nhưng không chứa nguyên văn câu trả lời vẫn có thể góp phần vào việc sinh ra câu trả lời đúng, điều không thể thực hiện được với các phương pháp trích xuất tiêu chuẩn, dẫn đến việc lấy biên trên các tài liệu hiệu quả hơn. Hơn nữa, RAG có thể sinh ra câu trả lời đúng ngay cả khi câu trả lời đúng không nằm trong bất kỳ tài liệu được truy xuất nào, đạt độ chính xác 11.8% trong những trường hợp như vậy đối với NQ, trong khi một mô hình trích xuất sẽ đạt 0%.

4.2 Hỏi đáp trừu tượng

Như thể hiện trong Bảng 2, RAG-Sequence vượt trội BART trên Open MS-MARCO NLG 2.6 điểm Bleu và 2.6 điểm Rouge-L. RAG tiệm cận hiệu năng của mô hình tiên tiến nhất, điều này rất ấn tượng khi xét rằng (i) các mô hình đó truy cập các đoạn văn chuẩn chứa thông tin cụ thể cần thiết để sinh câu trả lời tham chiếu, (ii) nhiều câu hỏi không thể trả lời nếu không có các đoạn văn chuẩn, và (iii) không phải câu hỏi nào cũng có thể trả lời chỉ từ Wikipedia. Bảng 3 trình bày một số câu trả lời được sinh bởi các mô hình của chúng tôi. Về mặt định tính, chúng tôi nhận thấy các mô hình RAG ít bị ảo giác hơn và sinh văn bản đúng sự thật thường xuyên hơn BART. Ở phần sau, chúng tôi cũng cho thấy văn bản do RAG sinh ra đa dạng hơn văn bản do BART sinh ra (xem §4.5).



Hình 2: Phân phối hậu nghiệm trên tài liệu $p(z_i|x, y_i, y_{-i})$ của RAG-Token cho mỗi token được sinh, với đầu vào "Hemingway" cho tác vụ sinh Jeopardy với 5 tài liệu được truy xuất. Phân phối hậu nghiệm của tài liệu 1 cao khi sinh "A Farewell to Arms" và của tài liệu 2 khi sinh "The Sun Also Rises".

Ghi chú của người dịch — nội dung hai tài liệu trong hình: **Tài liệu 1**: các tác phẩm của ông được coi là kinh điển của văn học Mỹ … Những trải nghiệm thời chiến của ông là cơ sở cho tiểu thuyết **"A Farewell to Arms"** (1929) … **Tài liệu 2**: … các nghệ sĩ của cộng đồng kiều dân "Thế hệ đã mất" (Lost Generation) những năm 1920. Tiểu thuyết đầu tay của ông, **"The Sun Also Rises"**, được xuất bản năm 1926.

4.3 Sinh câu hỏi Jeopardy

Bảng 2 cho thấy RAG-Token hoạt động tốt hơn RAG-Sequence trong việc sinh câu hỏi Jeopardy, và cả hai mô hình đều vượt trội BART trên Q-BLEU-1. Bảng 4 trình bày kết quả đánh giá của con người trên 452 cặp văn bản sinh từ BART và RAG-Token. Người đánh giá cho biết BART đúng sự thật hơn RAG chỉ trong 7.1% trường hợp, trong khi RAG đúng sự thật hơn trong 42.7% trường hợp, và cả RAG lẫn BART đều đúng sự thật trong thêm 17% trường hợp nữa, chứng tỏ rõ ràng hiệu quả của RAG trên tác vụ này so với một mô hình sinh tiên tiến nhất. Người đánh giá cũng nhận thấy văn bản do RAG sinh ra cụ thể hơn với cách biệt lớn. Bảng 3 trình bày các văn bản sinh điển hình từ mỗi mô hình.

Các câu hỏi Jeopardy thường chứa hai mẩu thông tin riêng biệt, và RAG-Token có thể hoạt động tốt nhất vì nó có thể sinh ra câu trả lời kết hợp nội dung từ nhiều tài liệu. Hình 2 minh hoạ một ví dụ. Khi sinh "Sun", phân phối hậu nghiệm (posterior) cao đối với tài liệu 2, tài liệu có đề cập đến "The Sun Also Rises". Tương tự, tài liệu 1 chiếm ưu thế trong phân phối hậu nghiệm khi "A Farewell to Arms" được sinh ra. Điều thú vị là, sau khi token đầu tiên của mỗi tên sách được sinh ra, phân phối hậu nghiệm trên các tài liệu trở nên phẳng. Quan sát này gợi ý rằng bộ sinh có thể hoàn thành các tựa sách mà không phụ thuộc vào các tài liệu cụ thể. Nói cách khác, tri thức tham số của mô hình là đủ để hoàn thành các tựa sách. Chúng tôi tìm thấy bằng chứng cho giả thuyết này bằng cách đưa cho mô hình cơ sở chỉ-BART phần giải mã dở dang `"The Sun`. BART hoàn thành việc sinh thành `"The Sun Also Rises" is a novel by this author of "The Sun Also Rises"`, cho thấy tựa sách "The Sun Also Rises" được lưu trữ trong các tham số của BART. Tương tự, BART sẽ hoàn thành phần giải mã dở dang `"The Sun Also Rises" is a novel by this author of "A` thành `"The Sun Also Rises" is a novel by this author of "A Farewell to Arms"`.[i] Ví dụ này cho thấy bộ nhớ tham số và phi tham số *phối hợp với nhau* như thế nào — thành phần phi tham số giúp định hướng quá trình sinh, khơi gợi những tri thức cụ thể được lưu trữ trong bộ nhớ tham số.

4.4 Kiểm chứng sự thật

Bảng 2 trình bày kết quả của chúng tôi trên FEVER. Với phân loại 3 lớp, điểm của RAG chỉ kém 4.3% so với các mô hình tiên tiến nhất, vốn là những hệ thống pipeline phức tạp với kiến trúc chuyên biệt cho miền và nhiều công sức kỹ thuật, được huấn luyện với giám sát truy xuất trung gian mà RAG không cần đến.

Với phân loại 2 lớp, chúng tôi so sánh với Thorne và Vlachos [57], những người huấn luyện

[i] *Ghi chú của người dịch:* Các chuỗi đơn cách là đầu ra nguyên văn (tiếng Anh) của mô hình. `"The Sun Also Rises" is a novel by this author of "…"` nghĩa là "'The Sun Also Rises' (*Mặt trời vẫn mọc*) là một tiểu thuyết của tác giả của '…'"; "A Farewell to Arms" là tiểu thuyết *Giã từ vũ khí*.

Bảng 3: Ví dụ từ các tác vụ sinh. Các mô hình RAG sinh ra câu trả lời cụ thể hơn và chính xác hơn về mặt sự thật. '?' biểu thị câu trả lời sai sự thật, * biểu thị câu trả lời đúng một phần. (Dòng in nghiêng màu xám là bản dịch tiếng Việt của người dịch; văn bản gốc do mô hình sinh ra bằng tiếng Anh.)

Tác vụ	Đầu vào	Mô hình	Văn bản được sinh
MS-MARCO	define middle ear *(định nghĩa tai giữa)*	BART	?The middle ear is the part of the ear between the middle ear and the nose. *Tai giữa là phần của tai nằm giữa tai giữa và mũi.*
		RAG-T	The middle ear is the portion of the ear internal to the eardrum. *Tai giữa là phần của tai nằm phía trong màng nhĩ.*
		RAG-S	The middle ear includes the tympanic cavity and the three ossicles. *Tai giữa bao gồm hòm nhĩ và ba xương con.*
	what currency needed in scotland *(ở Scotland cần dùng tiền tệ gì)*	BART	The currency needed in Scotland is Pound sterling. *Tiền tệ cần dùng ở Scotland là bảng Anh (Pound sterling).*
		RAG-T	Pound is the currency needed in Scotland. *Bảng là tiền tệ cần dùng ở Scotland.*
		RAG-S	The currency needed in Scotland is the pound sterling. *Tiền tệ cần dùng ở Scotland là đồng bảng Anh.*
Sinh câu hỏi Jeopardy	Washington	BART	?This state has the largest number of counties in the U.S. *Bang này có số hạt nhiều nhất nước Mỹ.*
		RAG-T	It's the only U.S. state named for a U.S. president *Đây là bang duy nhất của Mỹ được đặt theo tên một tổng thống Mỹ*
		RAG-S	It's the state where you'll find Mount Rainier National Park *Đây là bang nơi bạn sẽ tìm thấy Vườn quốc gia Núi Rainier*
	The Divine Comedy *(Thần khúc)*	BART	*This epic poem by Dante is divided into 3 parts: the Inferno, the Purgatorio & the Purgatorio *Bản sử thi này của Dante được chia thành 3 phần: Inferno, Purgatorio & Purgatorio*
		RAG-T	Dante's "Inferno" is the first part of this epic poem *"Inferno" (Địa ngục) của Dante là phần đầu tiên của bản sử thi này*
		RAG-S	This 14th century work is divided into 3 sections: "Inferno", "Purgatorio" & "Paradiso" *Tác phẩm thế kỷ 14 này được chia thành 3 phần: "Inferno", "Purgatorio" & "Paradiso"*

RoBERTa [35] để phân loại khẳng định là đúng hay sai khi được cho câu bằng chứng chuẩn. RAG đạt độ chính xác chỉ kém 2.7% so với mô hình này, mặc dù chỉ được cung cấp khẳng định và tự truy xuất bằng chứng của riêng mình. Chúng tôi cũng phân tích xem các tài liệu được RAG truy xuất có tương ứng với các tài liệu được chú thích là bằng chứng chuẩn trong FEVER hay không. Chúng tôi tính mức độ trùng lặp về tiêu đề bài viết giữa top k tài liệu được RAG truy xuất và các chú thích bằng chứng chuẩn. Chúng tôi nhận thấy tài liệu được truy xuất đứng đầu thuộc về một bài viết chuẩn trong 71% trường hợp, và một bài viết chuẩn có mặt trong top 10 bài viết được truy xuất trong 90% trường hợp.

4.5 Kết quả bổ sung

Tính đa dạng của văn bản sinh Mục 4.3 cho thấy các mô hình RAG đúng sự thật hơn và cụ thể hơn BART trong việc sinh câu hỏi Jeopardy. Theo các công trình gần đây về giải mã thúc đẩy tính đa dạng [33, 59, 39], chúng tôi cũng khảo sát tính đa dạng của văn bản sinh bằng cách tính tỷ lệ giữa số n-gram khác nhau và tổng số n-gram được sinh bởi các mô hình khác nhau. Bảng 5 cho thấy văn bản sinh của RAG-Sequence đa dạng hơn của RAG-Token, và cả hai đều đa dạng hơn đáng kể so với BART mà không cần bất kỳ phương pháp giải mã thúc đẩy đa dạng nào.

Thí nghiệm cắt bỏ thành phần truy xuất (Retrieval Ablations) Một đặc điểm then chốt của RAG là học cách truy xuất thông tin liên quan cho tác vụ. Để đánh giá hiệu quả của cơ chế truy xuất, chúng tôi chạy các thí nghiệm cắt bỏ (ablation) trong đó bộ truy xuất bị đóng băng trong quá trình huấn luyện. Như thể hiện trong Bảng 6, truy xuất được học giúp cải thiện kết quả trên tất cả các tác vụ.

Bảng 4: Đánh giá của con người cho tác vụ sinh câu hỏi Jeopardy.

	Tính xác thực	Tính cụ thể
BART tốt hơn	7.1%	16.8%
RAG tốt hơn	**42.7%**	**37.4%**
Cả hai đều tốt	11.7%	11.8%
Cả hai đều kém	17.7%	6.9%
Không có đa số	20.8%	20.1%

Bảng 5: Tỷ lệ giữa số tri-gram khác nhau và tổng số tri-gram cho các tác vụ sinh.

	MSMARCO	Jeopardy QGen
Chuẩn (Gold)	89.6%	90.0%
BART	70.7%	32.4%
RAG-Token	77.8%	46.8%
RAG-Seq.	83.5%	53.8%

Bảng 6: Các thí nghiệm cắt bỏ trên tập phát triển (dev). Vì FEVER là một tác vụ phân loại, hai mô hình RAG là tương đương.

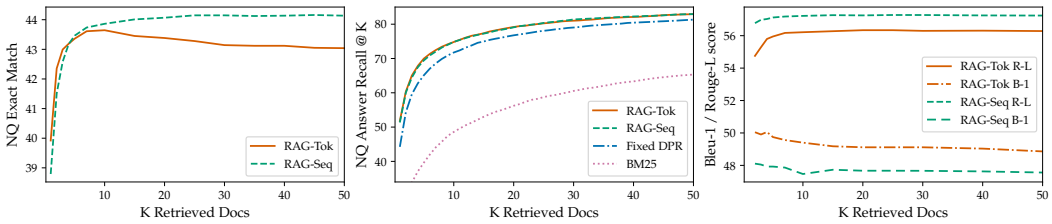
Mô hình	NQ	TQA	WQ	CT	Jeopardy-QGen		MSMarco		FVR-3	FVR-2
	Khớp chính xác				B-1	QB-1	R-L	B-1	Độ chính xác nhãn	
RAG-Token-BM25	29.7	41.5	32.1	33.1	17.5	22.3	55.5	48.4	**75.1**	**91.6**
RAG-Sequence-BM25	31.8	44.1	36.6	33.8	11.1	19.5	56.5	46.9		
RAG-Token-Frozen	37.8	50.1	37.1	51.1	16.7	21.7	55.9	49.4	72.9	89.4
RAG-Sequence-Frozen	41.2	52.1	41.8	52.6	11.8	19.6	56.7	47.3		
RAG-Token	43.5	54.8	**46.5**	51.9	**17.9**	**22.6**	56.2	**49.4**	74.5	90.6
RAG-Sequence	**44.0**	**55.8**	44.9	**53.4**	15.3	21.5	**57.2**	47.5		

Chúng tôi so sánh bộ truy xuất dày đặc của RAG với bộ truy xuất BM25 [53] dựa trên sự trùng lặp từ. Ở đây, chúng tôi thay thế bộ truy xuất của RAG bằng một hệ thống BM25 cố định, và sử dụng điểm truy xuất BM25 làm logit khi tính $p(z|x)$. Bảng 6 trình bày kết quả. Với FEVER, BM25 hoạt động tốt nhất, có lẽ vì các khẳng định trong FEVER tập trung nhiều vào thực thể và do đó rất phù hợp với truy xuất dựa trên trùng lặp từ. Truy xuất khả vi cải thiện kết quả trên tất cả các tác vụ khác, đặc biệt là với QA miền mở, nơi nó đóng vai trò then chốt.

Hoán đổi nóng chỉ mục (Index hot-swapping) Một lợi thế của các mô hình có bộ nhớ phi tham số như RAG là tri thức có thể dễ dàng được cập nhật tại thời điểm kiểm thử. Các mô hình chỉ có tham số như T5 hay BART cần được huấn luyện thêm để cập nhật hành vi khi thế giới thay đổi. Để minh chứng, chúng tôi xây dựng một chỉ mục sử dụng bản kết xuất Wikipedia của DrQA [5] từ tháng 12 năm 2016 và so sánh đầu ra của RAG khi dùng chỉ mục này với chỉ mục mới hơn trong các kết quả chính của chúng tôi (tháng 12 năm 2018). Chúng tôi chuẩn bị một danh sách 82 nhà lãnh đạo thế giới đã thay đổi

giữa hai thời điểm này và sử dụng mẫu câu "Who is {position}?" ("Ai là {chức vụ}?", ví dụ "Who is the President of Peru?" — "Ai là Tổng thống Peru?") để truy vấn mô hình RAG trên NQ của chúng tôi với mỗi chỉ mục. RAG trả lời đúng 70% khi dùng chỉ mục 2016 cho các nhà lãnh đạo thế giới năm 2016 và 68% khi dùng chỉ mục 2018 cho các nhà lãnh đạo thế giới năm 2018. Độ chính xác với các chỉ mục không khớp thì thấp (12% với chỉ mục 2018 và các nhà lãnh đạo 2016, 4% với chỉ mục 2016 và các nhà lãnh đạo 2018). Điều này cho thấy chúng ta có thể cập nhật tri thức về thế giới của RAG chỉ bằng cách thay thế bộ nhớ phi tham số của nó.

Ảnh hưởng của việc truy xuất nhiều tài liệu hơn Các mô hình được huấn luyện với 5 hoặc 10 tài liệu ẩn được truy xuất, và chúng tôi không quan sát thấy khác biệt đáng kể về hiệu năng giữa hai thiết lập này. Chúng tôi có thể linh hoạt điều chỉnh số lượng tài liệu được truy xuất tại thời điểm kiểm thử, điều này có thể ảnh hưởng đến hiệu năng và thời gian chạy. Hình 3 (trái) cho thấy việc truy xuất nhiều tài liệu hơn tại thời điểm kiểm thử cải thiện đơn điệu kết quả QA miền mở của RAG-Sequence, nhưng hiệu năng của RAG-Token đạt đỉnh ở 10 tài liệu được truy xuất. Hình 3 (phải) cho thấy việc



Hình 3: Trái: Hiệu năng trên NQ khi truy xuất nhiều tài liệu hơn. Giữa: Độ phủ (recall) truy xuất trên NQ. Phải: Bleu-1 và Rouge-L trên MS-MARCO khi truy xuất nhiều tài liệu hơn.

truy xuất nhiều tài liệu hơn dẫn đến Rouge-L cao hơn cho RAG-Token nhưng phải đánh đổi bằng Bleu-1, trong khi ảnh hưởng này ít rõ rệt hơn đối với RAG-Sequence.

5 Các công trình liên quan

Truy xuất cho từng tác vụ đơn lẻ Các công trình trước đây đã chỉ ra rằng truy xuất cải thiện hiệu năng trên nhiều tác vụ NLP khác nhau khi được xem xét riêng lẻ. Các tác vụ đó bao gồm hỏi đáp miền mở [5, 29], kiểm tra sự thật [56], hoàn thiện sự kiện (fact completion) [48], hỏi đáp dạng dài [12], sinh bài viết Wikipedia [36], hội thoại [41, 65, 9, 13], dịch máy [17], và mô hình hoá ngôn ngữ [19, 27]. Công trình của chúng tôi hợp nhất những thành công trước đây trong việc tích hợp truy xuất vào từng tác vụ riêng lẻ, cho thấy rằng một kiến trúc duy nhất dựa trên truy xuất có khả năng đạt hiệu năng mạnh trên nhiều tác vụ.

Kiến trúc đa dụng cho NLP Các công trình trước đây về kiến trúc đa dụng cho các tác vụ NLP đã đạt thành công lớn mà không cần sử dụng truy xuất. Một mô hình ngôn ngữ duy nhất được huấn luyện trước đã được chứng minh là đạt hiệu năng mạnh trên nhiều tác vụ phân loại trong các bộ benchmark GLUE [60, 61] sau khi tinh chỉnh [49, 8]. GPT-2 [50] sau đó cho thấy rằng một mô hình ngôn ngữ duy nhất, từ trái sang phải, được huấn luyện trước có thể đạt hiệu năng mạnh trên cả các tác vụ phân biệt (discriminative) lẫn tác vụ sinh (generative). Để cải thiện hơn nữa, BART [32] và T5 [51, 52] đề xuất một mô hình mã hoá–giải mã duy nhất, được huấn luyện trước, tận dụng cơ chế chú ý hai chiều để đạt hiệu năng mạnh hơn trên các tác vụ phân biệt và tác vụ sinh. Công trình của chúng tôi nhằm mở rộng không gian các tác vụ khả thi với một kiến trúc thống nhất duy nhất, bằng cách học một mô-đun truy xuất để tăng cường cho các mô hình ngôn ngữ sinh đã được huấn luyện trước.

Truy xuất được học Có nhiều công trình đáng kể về việc học cách truy xuất tài liệu trong lĩnh vực truy xuất thông tin, gần đây hơn là với các mô hình ngôn ngữ nơ-ron được huấn luyện trước [44, 26] tương tự như của chúng tôi. Một số công trình tối ưu hoá mô-đun truy xuất để hỗ trợ một tác vụ hạ nguồn cụ thể như hỏi đáp, sử dụng tìm kiếm [46], học tăng cường [6, 63, 62], hoặc một cách tiếp cận biến ẩn [31, 20] như trong công trình của chúng tôi. Những thành công này tận dụng các kiến trúc dựa trên truy xuất và kỹ thuật tối ưu hoá khác nhau để đạt hiệu năng mạnh trên một tác vụ duy nhất, trong khi chúng tôi cho thấy rằng một kiến trúc duy nhất dựa trên truy xuất có thể được tinh chỉnh để đạt hiệu năng mạnh trên nhiều tác vụ khác nhau.

Kiến trúc dựa trên bộ nhớ Chỉ mục tài liệu của chúng tôi có thể được xem như một bộ nhớ ngoài lớn để các mạng nơ-ron chú ý (attend) tới, tương tự như mạng bộ nhớ [64, 55]. Một công trình đồng thời [14] học cách truy xuất một vectơ nhúng đã huấn luyện cho mỗi thực thể trong đầu vào, thay vì truy xuất văn bản thô như trong công trình của chúng tôi. Các công trình khác cải thiện khả năng của mô hình hội thoại trong việc sinh văn bản đúng sự thật bằng cách chú ý tới các vectơ nhúng sự kiện [15, 13]. Một đặc điểm then chốt của bộ nhớ của chúng tôi là nó bao gồm văn bản thô thay vì các biểu diễn phân tán, điều này làm cho bộ nhớ vừa (i) con người đọc được, mang lại một dạng khả năng diễn giải cho mô hình, vừa (ii) con người viết được, cho phép chúng tôi cập nhật động bộ nhớ

của mô hình bằng cách chỉnh sửa chỉ mục tài liệu. Cách tiếp cận này cũng đã được sử dụng trong hội thoại đòi hỏi nhiều tri thức, trong đó các bộ sinh được điều kiện hoá trực tiếp trên văn bản được truy xuất, mặc dù văn bản này thu được thông qua TF-IDF thay vì truy xuất được học đầu-cuối [9].

Các phương pháp Truy xuất-và-Chỉnh sửa (Retrieve-and-Edit) Phương pháp của chúng tôi có một số điểm tương đồng với các phương pháp kiểu truy xuất-và-chỉnh sửa, trong đó một cặp đầu vào–đầu ra huấn luyện tương tự được truy xuất cho một đầu vào cho trước, rồi được chỉnh sửa để tạo ra đầu ra cuối cùng. Những phương pháp này đã chứng tỏ thành công trong nhiều lĩnh vực bao gồm Dịch máy [18, 22] và Phân tích ngữ nghĩa (Semantic Parsing) [21]. Cách tiếp cận của chúng tôi có một số khác biệt, bao gồm việc ít chú trọng vào chỉnh sửa nhẹ một mục được truy xuất, mà chú trọng vào việc tổng hợp nội dung từ nhiều mẩu nội dung được truy xuất, cũng như học truy xuất ẩn, và truy xuất các tài liệu bằng chứng thay vì các cặp huấn luyện liên quan. Dù vậy, các kỹ thuật RAG có thể hoạt động tốt trong những bối cảnh này và có thể là một hướng nghiên cứu tương lai đầy hứa hẹn.

6 Thảo luận

Trong công trình này, chúng tôi đã trình bày các mô hình sinh lai có quyền truy cập vào bộ nhớ tham số và phi tham số. Chúng tôi đã cho thấy các mô hình RAG của mình đạt kết quả tiên tiến nhất trên QA miền mở. Chúng tôi nhận thấy mọi người ưa thích văn bản do RAG sinh ra hơn so với BART thuần tham số, đánh giá RAG là đúng sự thật hơn và cụ thể hơn. Chúng tôi đã tiến hành một khảo sát kỹ lưỡng về thành phần truy xuất được học, xác nhận hiệu quả của nó, và minh hoạ cách chỉ mục truy xuất có thể được hoán đổi nóng để cập nhật mô hình mà không cần huấn luyện lại. Trong tương lai, có thể sẽ hữu ích nếu nghiên cứu liệu hai thành phần có thể được huấn luyện trước đồng thời từ đầu hay không, với một mục tiêu khử nhiễu tương tự BART hoặc một mục tiêu khác. Công trình của chúng tôi mở ra những hướng nghiên cứu mới về cách bộ nhớ tham số và phi tham số tương tác với nhau và cách kết hợp chúng hiệu quả nhất, cho thấy triển vọng được áp dụng vào nhiều tác vụ NLP khác nhau.

Tác động rộng hơn

Công trình này mang lại một số lợi ích tích cực cho xã hội so với các công trình trước đây: việc nó được neo chặt hơn vào tri thức thực tế (trong trường hợp này là Wikipedia) khiến nó ít "ảo giác" hơn, với văn bản sinh ra đúng sự thật hơn, đồng thời mang lại khả năng kiểm soát và diễn giải tốt hơn. RAG có thể được sử dụng trong nhiều kịch bản khác nhau mang lại lợi ích trực tiếp cho xã hội, ví dụ bằng cách trang bị cho nó một chỉ mục y khoa và đặt các câu hỏi miền mở về chủ đề đó, hoặc bằng cách giúp mọi người làm việc hiệu quả hơn.

Đi kèm với những lợi thế này cũng là những nhược điểm tiềm ẩn: Wikipedia, hay bất kỳ nguồn tri thức bên ngoài tiềm năng nào, có lẽ sẽ không bao giờ hoàn toàn đúng sự thật và hoàn toàn không có thiên kiến. Vì RAG có thể được sử dụng như một mô hình ngôn ngữ, những lo ngại tương tự như đối với GPT-2 [50] cũng đúng ở đây, dù có lẽ ở mức độ thấp hơn, bao gồm việc nó có thể bị sử dụng để tạo ra nội dung lăng mạ, giả mạo hoặc gây hiểu lầm trên tin tức hay mạng xã hội; để mạo danh người khác; hoặc để tự động hoá việc sản xuất nội dung thư rác/lừa đảo (spam/phishing) [54]. Các mô hình ngôn ngữ tiên tiến cũng có thể dẫn đến việc tự động hoá nhiều công việc khác nhau trong những thập kỷ tới [16]. Để giảm thiểu những rủi ro này, các hệ thống AI có thể được sử dụng để chống lại nội dung gây hiểu lầm và thư rác/lừa đảo tự động.

Lời cảm ơn

Các tác giả xin cảm ơn các nhà phản biện vì những góp ý sâu sắc và mang tính xây dựng cho bài báo này, cũng như HuggingFace vì đã giúp đỡ trong việc công bố mã nguồn mở để chạy các mô hình RAG. Các tác giả cũng xin cảm ơn Kyunghyun Cho và Sewon Min vì những thảo luận và lời khuyên

hữu ích. EP cảm ơn sự hỗ trợ từ Học bổng Nghiên cứu Sau đại học của NSF (NSF Graduate Research Fellowship). PL được hỗ trợ bởi chương trình Tiến sĩ của FAIR (FAIR PhD program).

Tài liệu tham khảo

[1] Payal Bajaj, Daniel Campos, Nick Craswell, Li Deng, Jianfeng Gao, Xiaodong Liu, Rangan Majumder, Andrew McNamara, Bhaskar Mitra, Tri Nguyen, Mir Rosenberg, Xia Song, Alina Stoica, Saurabh Tiwary, and Tong Wang. MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. arXiv:1611.09268 [cs], November 2016. URL http://arxiv.org/abs/1611.09268. arXiv: 1611.09268.

[2] Petr Baudiš and Jan Šedivý. Modeling of the question answering task in the yodaqa system. In *International Conference of the Cross-Language Evaluation Forum for European Languages*, pages 222–228. Springer, 2015. URL https://link.springer.com/chapter/10.1007%2F978-3-319-24027-5_20.

[3] Jonathan Berant, Andrew Chou, Roy Frostig, and Percy Liang. Semantic Parsing on Freebase from Question-Answer Pairs. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 1533–1544, Seattle, Washington, USA, October 2013. Association for Computational Linguistics. URL http://www.aclweb.org/anthology/D13-1160.

[4] Bin Bi, Chenliang Li, Chen Wu, Ming Yan, and Wei Wang. Palm: Pre-training an autoencoding&autoregressive language model for context-conditioned generation. *ArXiv*, abs/2004.07159, 2020. URL https://arxiv.org/abs/2004.07159.

[5] Danqi Chen, Adam Fisch, Jason Weston, and Antoine Bordes. Reading Wikipedia to Answer Open-Domain Questions. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1870–1879, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1171. URL https://www.aclweb.org/anthology/P17-1171.

[6] Eunsol Choi, Daniel Hewlett, Jakob Uszkoreit, Illia Polosukhin, Alexandre Lacoste, and Jonathan Berant. Coarse-to-fine question answering for long documents. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 209–220, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1020. URL https://www.aclweb.org/anthology/P17-1020.

[7] Christopher Clark and Matt Gardner. Simple and Effective Multi-Paragraph Reading Comprehension. arXiv:1710.10723 [cs], October 2017. URL http://arxiv.org/abs/1710.10723. arXiv: 1710.10723.

[8] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL https://www.aclweb.org/anthology/N19-1423.

[9] Emily Dinan, Stephen Roller, Kurt Shuster, Angela Fan, Michael Auli, and Jason Weston. Wizard of wikipedia: Knowledge-powered conversational agents. In *International Conference on Learning Representations*, 2019. URL https://openreview.net/forum?id=r1l73iRqKm.

[10] Matthew Dunn, Levent Sagun, Mike Higgins, V. Ugur Guney, Volkan Cirik, and Kyunghyun Cho. SearchQA: A New Q&A Dataset Augmented with Context from a Search Engine. arXiv:1704.05179 [cs], April 2017. URL http://arxiv.org/abs/1704.05179. arXiv: 1704.05179.

[11] Angela Fan, Mike Lewis, and Yann Dauphin. Hierarchical neural story generation. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 889–898, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1082. URL https://www.aclweb.org/anthology/P18-1082.

[12] Angela Fan, Yacine Jernite, Ethan Perez, David Grangier, Jason Weston, and Michael Auli. ELI5: Long form question answering. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3558–3567, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1346. URL https://www.aclweb.org/anthology/P19-1346.

[13] Angela Fan, Claire Gardent, Chloe Braud, and Antoine Bordes. Augmenting transformers with KNN-based composite memory, 2020. URL https://openreview.net/forum?id=H1gx1CNKPH.

[14] Thibault Févry, Livio Baldini Soares, Nicholas FitzGerald, Eunsol Choi, and Tom Kwiatkowski. Entities as experts: Sparse memory access with entity supervision. *ArXiv*, abs/2004.07202, 2020. URL https://arxiv.org/abs/2004.07202.

[15] Marjan Ghazvininejad, Chris Brockett, Ming-Wei Chang, Bill Dolan, Jianfeng Gao, Wen tau Yih, and Michel Galley. A knowledge-grounded neural conversation model. In *AAAI Conference on Artificial Intelligence*, 2018. URL https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/16710.

[16] Katja Grace, John Salvatier, Allan Dafoe, Baobao Zhang, and Owain Evans. When will AI exceed human performance? evidence from AI experts. *CoRR*, abs/1705.08807, 2017. URL http://arxiv.org/abs/1705.08807.

[17] Jiatao Gu, Yong Wang, Kyunghyun Cho, and Victor O.K. Li. Search engine guided neural machine translation. In *AAAI Conference on Artificial Intelligence*, 2018. URL https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/17282.

[18] Jiatao Gu, Yong Wang, Kyunghyun Cho, and Victor O.K. Li. Search engine guided neural machine translation. In *32nd AAAI Conference on Artificial Intelligence, AAAI 2018*, 32nd AAAI Conference on Artificial Intelligence, AAAI 2018, pages 5133–5140. AAAI press, 2018. 32nd AAAI Conference on Artificial Intelligence, AAAI 2018 ; Conference date: 02-02-2018 Through 07-02-2018.

[19] Kelvin Guu, Tatsunori B. Hashimoto, Yonatan Oren, and Percy Liang. Generating sentences by editing prototypes. *Transactions of the Association for Computational Linguistics*, 6:437–450, 2018. doi: 10.1162/tacl_a_00030. URL https://www.aclweb.org/anthology/Q18-1031.

[20] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. REALM: Retrieval-augmented language model pre-training. *ArXiv*, abs/2002.08909, 2020. URL https://arxiv.org/abs/2002.08909.

[21] Tatsunori B Hashimoto, Kelvin Guu, Yonatan Oren, and Percy S Liang. A retrieve-and-edit framework for predicting structured outputs. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 10052–10062. Curran Associates, Inc., 2018. URL http://papers.nips.cc/paper/8209-a-retrieve-and-edit-framework-for-predicting-structured-outputs.pdf.

[22] Nabil Hossain, Marjan Ghazvininejad, and Luke Zettlemoyer. Simple and effective retrieve-edit-rerank text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2532–2538, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.228. URL https://www.aclweb.org/anthology/2020.acl-main.228.

[23] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with gpus. *arXiv preprint arXiv:1702.08734*, 2017. URL https://arxiv.org/abs/1702.08734.

[24] Mandar Joshi, Eunsol Choi, Daniel Weld, and Luke Zettlemoyer. TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1601–1611, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1147. URL https://www.aclweb.org/anthology/P17-1147.

[25] Armand Joulin and Tomas Mikolov. Inferring algorithmic patterns with stack-augmented recurrent nets. In *Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 1*, NIPS'15, page 190–198, Cambridge, MA, USA, 2015. MIT Press. URL https://papers.nips.cc/paper/5857-inferring-algorithmic-patterns-with-stack-augmented-recurrent-nets.

[26] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. *arXiv preprint arXiv:2004.04906*, 2020. URL https://arxiv.org/abs/2004.04906.

[27] Urvashi Khandelwal, Omer Levy, Dan Jurafsky, Luke Zettlemoyer, and Mike Lewis. Generalization through memorization: Nearest neighbor language models. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=HklBjCEKvH.

[28] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL http://arxiv.org/abs/1412.6980.

[29] Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Matthew Kelcey, Jacob Devlin, Kenton Lee, Kristina N. Toutanova, Llion Jones, Ming-Wei Chang, Andrew Dai, Jakob Uszkoreit, Quoc Le, and Slav Petrov. Natural Questions: a Benchmark for Question Answering Research. *Transactions of the Association of Computational Linguistics*, 2019. URL https://tomkwiat.users.x20web.corp.google.com/papers/natural-questions/main-1455-kwiatkowski.pdf.

[30] Guillaume Lample, Alexandre Sablayrolles, Marc' Aurelio Ranzato, Ludovic Denoyer, and Herve Jegou. Large memory layers with product keys. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d' Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 8548–8559. Curran Associates, Inc., 2019. URL http://papers.nips.cc/paper/9061-large-memory-layers-with-product-keys.pdf.

[31] Kenton Lee, Ming-Wei Chang, and Kristina Toutanova. Latent retrieval for weakly supervised open domain question answering. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 6086–6096, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1612. URL https://www.aclweb.org/anthology/P19-1612.

[32] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, and Luke Zettlemoyer. BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. *arXiv preprint arXiv:1910.13461*, 2019. URL https://arxiv.org/abs/1910.13461.

[33] Jiwei Li, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. A diversity-promoting objective function for neural conversation models. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 110–119, San Diego, California, June 2016. Association for Computational Linguistics. doi: 10.18653/v1/N16-1014. URL https://www.aclweb.org/anthology/N16-1014.

[34] Margaret Li, Jason Weston, and Stephen Roller. Acute-eval: Improved dialogue evaluation with optimized questions and multi-turn comparisons. *ArXiv*, abs/1909.03087, 2019. URL https://arxiv.org/abs/1909.03087.

[35] Hairong Liu, Mingbo Ma, Liang Huang, Hao Xiong, and Zhongjun He. Robust neural machine translation with joint textual and phonetic embedding. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3044–3049, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1291. URL https://www.aclweb.org/anthology/P19-1291.

[36] Peter J. Liu*, Mohammad Saleh*, Etienne Pot, Ben Goodrich, Ryan Sepassi, Lukasz Kaiser, and Noam Shazeer. Generating wikipedia by summarizing long sequences. In *International Conference on Learning Representations*, 2018. URL https://openreview.net/forum?id=Hyg0vbWC-.

[37] Yury A. Malkov and D. A. Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42:824–836, 2016. URL https://arxiv.org/abs/1603.09320.

[38] Gary Marcus. The next decade in ai: four steps towards robust artificial intelligence. *arXiv preprint arXiv:2002.06177*, 2020. URL https://arxiv.org/abs/2002.06177.

[39] Luca Massarelli, Fabio Petroni, Aleksandra Piktus, Myle Ott, Tim Rocktäschel, Vassilis Plachouras, Fabrizio Silvestri, and Sebastian Riedel. How decoding strategies affect the verifiability of generated text. *arXiv preprint arXiv:1911.03587*, 2019. URL https://arxiv.org/abs/1911.03587.

[40] Paulius Micikevicius, Sharan Narang, Jonah Alben, Gregory Diamos, Erich Elsen, David Garcia, Boris Ginsburg, Michael Houston, Oleksii Kuchaiev, Ganesh Venkatesh, and Hao Wu. Mixed precision training. In *ICLR*, 2018. URL https://openreview.net/forum?id=r1gs9JgRZ.

[41] Nikita Moghe, Siddhartha Arora, Suman Banerjee, and Mitesh M. Khapra. Towards exploiting background knowledge for building conversation systems. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 2322–2332, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1255. URL https://www.aclweb.org/anthology/D18-1255.

[42] Preksha Nema and Mitesh M. Khapra. Towards a better metric for evaluating question generation systems. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 3950–3959, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1429. URL https://www.aclweb.org/anthology/D18-1429.

[43] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, and Li Deng. MS MARCO: A human generated machine reading comprehension dataset. In Tarek Richard Besold, Antoine Bordes, Artur S. d'Avila Garcez, and Greg Wayne, editors, *Proceedings of the Workshop on Cognitive Computation: Integrating neural and symbolic approaches 2016 co-located with the 30th Annual Conference on Neural Information Processing Systems (NIPS 2016), Barcelona, Spain, December 9, 2016*, volume 1773 of *CEUR Workshop Proceedings*. CEUR-WS.org, 2016. URL http://ceur-ws.org/Vol-1773/CoCoNIPS_2016_paper9.pdf.

[44] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019. URL https://arxiv.org/abs/1901.04085.

[45] Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, and Michael Auli. fairseq: A fast, extensible toolkit for sequence modeling. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (Demonstrations)*, pages 48–53, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-4009. URL https://www.aclweb.org/anthology/N19-4009.

[46] Ethan Perez, Siddharth Karamcheti, Rob Fergus, Jason Weston, Douwe Kiela, and Kyunghyun Cho. Finding generalizable evidence by learning to convince q&a models. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2402–2411, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1244. URL https://www.aclweb.org/anthology/D19-1244.

[47] Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. Language models as knowledge bases? In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2463–2473, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1250. URL https://www.aclweb.org/anthology/D19-1250.

[48] Fabio Petroni, Patrick Lewis, Aleksandra Piktus, Tim Rocktäschel, Yuxiang Wu, Alexander H. Miller, and Sebastian Riedel. How context affects language models' factual predictions. In *Automated Knowledge Base Construction*, 2020. URL https://openreview.net/forum?id=025X0zPfn.

[49] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving Language Understanding by Generative Pre-Training, 2018. URL https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/language-unsupervised/language_understanding_paper.pdf.

[50] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners, 2019. URL https://d4mucfpksywv.cloudfront.net/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.

[51] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *arXiv e-prints*, 2019. URL https://arxiv.org/abs/1910.10683.

[52] Adam Roberts, Colin Raffel, and Noam Shazeer. How much knowledge can you pack into the parameters of a language model? *arXiv e-prints*, 2020. URL https://arxiv.org/abs/2002.08910.

[53] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: Bm25 and beyond. *Found. Trends Inf. Retr.*, 3(4):333–389, April 2009. ISSN 1554-0669. doi: 10.1561/1500000019. URL https://doi.org/10.1561/1500000019.

[54] Irene Solaiman, Miles Brundage, Jack Clark, Amanda Askell, Ariel Herbert-Voss, Jeff Wu, Alec Radford, and Jian-Bing Wang. Release strategies and the social impacts of language models. *ArXiv*, abs/1908.09203, 2019.

[55] Sainbayar Sukhbaatar, Arthur Szlam, Jason Weston, and Rob Fergus. End-to-end memory networks. In C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems 28*, pages 2440–2448. Curran Associates, Inc., 2015. URL http://papers.nips.cc/paper/5846-end-to-end-memory-networks.pdf.

[56] James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana, June 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-1074. URL https://www.aclweb.org/anthology/N18-1074.

[57] James H. Thorne and Andreas Vlachos. Avoiding catastrophic forgetting in mitigating model biases in sentence-pair classification with elastic weight consolidation. *ArXiv*, abs/2004.14366, 2020. URL https://arxiv.org/abs/2004.14366.

[58] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 5998–6008. Curran Associates, Inc., 2017. URL http://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf.

[59] Ashwin Vijayakumar, Michael Cogswell, Ramprasaath Selvaraju, Qing Sun, Stefan Lee, David Crandall, and Dhruv Batra. Diverse beam search for improved description of complex scenes. *AAAI Conference on Artificial Intelligence*, 2018. URL https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/17329.

[60] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. GLUE: A multi-task benchmark and analysis platform for natural language understanding. In *Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, pages 353–355, Brussels, Belgium, November 2018. Association for Computational Linguistics. doi: 10.18653/v1/W18-5446. URL https://www.aclweb.org/anthology/W18-5446.

[61] Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 3261–3275. Curran Associates, Inc., 2019. URL https://arxiv.org/abs/1905.00537.

[62] Shuohang Wang, Mo Yu, Xiaoxiao Guo, Zhiguo Wang, Tim Klinger, Wei Zhang, Shiyu Chang, Gerry Tesauro, Bowen Zhou, and Jing Jiang. R3: Reinforced ranker-reader for open-domain question answering. In Sheila A. McIlraith and Kilian Q. Weinberger, editors, *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, (AAAI-18), the 30th innovative Applications of Artificial Intelligence (IAAI-18), and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence (EAAI-18), New Orleans, Louisiana, USA, February 2-7, 2018*, pages 5981–5988. AAAI Press, 2018. URL https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/16712.

[63] Shuohang Wang, Mo Yu, Jing Jiang, Wei Zhang, Xiaoxiao Guo, Shiyu Chang, Zhiguo Wang, Tim Klinger, Gerald Tesauro, and Murray Campbell. Evidence aggregation for answer re-ranking in open-domain question answering. In *ICLR*, 2018. URL https://openreview.net/forum?id=rJl3yM-Ab.

[64] Jason Weston, Sumit Chopra, and Antoine Bordes. Memory networks. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL http://arxiv.org/abs/1410.3916.

[65] Jason Weston, Emily Dinan, and Alexander Miller. Retrieve and refine: Improved sequence generation models for dialogue. In *Proceedings of the 2018 EMNLP Workshop SCAI: The 2nd International Workshop on Search-Oriented Conversational AI*, pages 87–92, Brussels, Belgium, October 2018. Association for Computational Linguistics. doi: 10.18653/v1/W18-5713. URL https://www.aclweb.org/anthology/W18-5713.

[66] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander M. Rush. Huggingface's transformers: State-of-the-art natural language processing. *ArXiv*, abs/1910.03771, 2019.

[67] Shiyue Zhang and Mohit Bansal. Addressing semantic drift in question generation for semi-supervised question answering. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2495–2509, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1253. URL https://www.aclweb.org/anthology/D19-1253.

[68] Wanjun Zhong, Jingjing Xu, Duyu Tang, Zenan Xu, Nan Duan, Ming Zhou, Jiahai Wang, and Jian Yin. Reasoning over semantic-level graph for fact checking. *ArXiv*, abs/1909.03745, 2019. URL https://arxiv.org/abs/1909.03745.

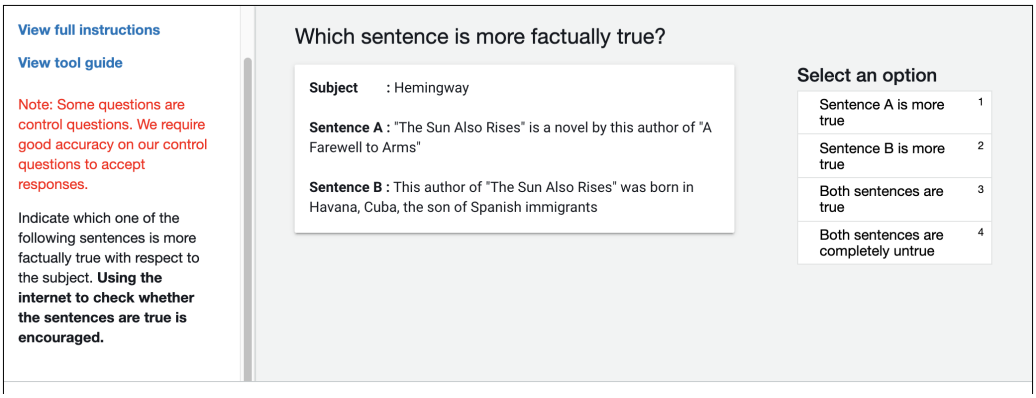
Phụ lục cho bài báo

Sinh văn bản tăng cường truy xuất cho các tác vụ NLP đòi hỏi nhiều tri thức

A Chi tiết triển khai

Với QA miền mở, chúng tôi báo cáo kết quả kiểm thử sử dụng 15 tài liệu được truy xuất cho các mô hình RAG-Token. Với các mô hình RAG-Sequence, chúng tôi báo cáo kết quả kiểm thử sử dụng 50 tài liệu được truy xuất, và sử dụng phương pháp Giải mã Kỹ lưỡng vì các câu trả lời nhìn chung ngắn. Chúng tôi sử dụng giải mã tham lam (greedy decoding) cho QA vì nhận thấy tìm kiếm chùm không cải thiện kết quả. Với Open-MSMarco và sinh câu hỏi Jeopardy, chúng tôi báo cáo kết quả kiểm thử sử dụng mười tài liệu được truy xuất cho cả RAG-Token và RAG-Sequence, và chúng tôi cũng huấn luyện một mô hình BART-large làm mô hình cơ sở. Chúng tôi sử dụng kích thước chùm (beam size) bằng bốn, và sử dụng phương pháp Giải mã Nhanh cho các mô hình RAG-Sequence, vì Giải mã Kỹ lưỡng không cải thiện hiệu năng.

B Đánh giá của con người



Hình 4: Giao diện chú thích cho đánh giá tính xác thực của con người. Một cửa sổ bật lên với hướng dẫn chi tiết và một ví dụ mẫu sẽ xuất hiện khi nhấp vào "view tool guide" (xem hướng dẫn công cụ).

Ghi chú của người dịch — nội dung giao diện: "Which sentence is more factually true?" = *Câu nào đúng sự thật hơn?* Chủ đề: Hemingway. Câu A: "'The Sun Also Rises' là một tiểu thuyết của tác giả của 'A Farewell to Arms'". Câu B: "Tác giả của 'The Sun Also Rises' sinh ra ở Havana, Cuba, là con của những người nhập cư Tây Ban Nha". Các lựa chọn: câu A đúng hơn; câu B đúng hơn; cả hai câu đều đúng; cả hai câu đều hoàn toàn sai. Cột trái: "Lưu ý: Một số câu hỏi là câu hỏi kiểm soát. Chúng tôi yêu cầu độ chính xác tốt trên các câu hỏi kiểm soát để chấp nhận câu trả lời. Hãy cho biết câu nào sau đây đúng sự thật hơn đối với chủ đề. Khuyến khích sử dụng internet để kiểm tra xem các câu có đúng hay không."

Hình 4 trình bày giao diện người dùng cho đánh giá của con người. Để tránh mọi thiên lệch do vị trí trên màn hình, việc mô hình nào tương ứng với câu A và câu B được chọn ngẫu nhiên cho mỗi ví dụ. Người chú thích được khuyến khích tìm hiểu chủ đề bằng internet, và được cung cấp hướng dẫn chi tiết cùng các ví dụ mẫu trong một thẻ hướng dẫn đầy đủ. Chúng tôi đưa vào một số câu chuẩn (gold) để đánh giá độ chính xác của người chú thích. Hai người chú thích đã không thực hiện tốt trên những ví dụ này và các chú thích của họ đã bị loại khỏi kết quả.

C Chi tiết thiết lập huấn luyện

Chúng tôi huấn luyện tất cả các mô hình RAG và các mô hình cơ sở BART bằng Fairseq [45].[2] Chúng tôi huấn luyện với số học dấu phẩy động độ chính xác hỗn hợp (mixed precision) [40], phân tán quá trình huấn luyện trên 8 GPU NVIDIA V100 32GB, mặc dù việc huấn luyện và suy luận có thể chạy trên một GPU. Chúng tôi nhận thấy việc thực hiện Tìm kiếm Tích vô hướng Cực đại với FAISS trên CPU là đủ nhanh, vì vậy chúng tôi lưu trữ các vectơ của chỉ mục tài liệu trên CPU, đòi hỏi khoảng ~100 GB bộ nhớ CPU cho toàn bộ Wikipedia. Sau khi nộp bài, chúng tôi đã chuyển mã nguồn sang HuggingFace Transformers [66][3], đạt hiệu năng tương đương với phiên bản trước nhưng là một bản cài đặt gọn gàng và dễ sử dụng hơn. Phiên bản này cũng được công bố mã nguồn mở. Chúng tôi cũng nén chỉ mục tài liệu bằng các công cụ nén của FAISS, giảm yêu cầu bộ nhớ CPU xuống 36GB. Các script để chạy thí nghiệm với RAG có thể được tìm thấy tại `https://github.com/huggingface/transformers/blob/master/examples/rag/README.md` và một bản demo tương tác của mô hình RAG có thể được tìm thấy tại `https://huggingface.co/rag/`

D Chi tiết bổ sung về QA miền mở

Đối với QA miền mở, một câu hỏi thường có nhiều chú thích câu trả lời. Các chú thích câu trả lời này được các mô hình trích xuất khai thác trong quá trình huấn luyện, vì thông thường tất cả các chú thích câu trả lời đều được sử dụng để tìm các đoạn khớp trong tài liệu khi chuẩn bị dữ liệu huấn luyện. Với RAG, chúng tôi cũng tận dụng nhiều ví dụ chú thích cho Natural Questions và WebQuestions bằng cách huấn luyện mô hình với từng cặp (q, a) riêng biệt, dẫn đến một mức tăng nhỏ về độ chính xác. Với TriviaQA, một câu hỏi thường có nhiều câu trả lời hợp lệ, một số trong đó không phù hợp làm mục tiêu huấn luyện, chẳng hạn như emoji hoặc các biến thể chính tả. Với TriviaQA, chúng tôi lọc bỏ các ứng viên câu trả lời nếu chúng không xuất hiện trong top 1000 tài liệu của truy vấn.

Tiền xử lý CuratedTrec Các câu trả lời của CuratedTrec được cho dưới dạng biểu thức chính quy (regular expression), điều này đã được cho là lý do khiến tập dữ liệu này không phù hợp với các mô hình sinh câu trả lời [20]. Để khắc phục điều này, chúng tôi sử dụng một bước tiền xử lý, trong đó trước tiên chúng tôi truy xuất top 1000 tài liệu cho mỗi truy vấn, và sử dụng câu trả lời khớp với mẫu regex thường xuyên nhất làm mục tiêu giám sát. Nếu không tìm thấy kết quả khớp nào, chúng tôi dùng đến một heuristic đơn giản: sinh tất cả các hoán vị có thể có cho mỗi regex, thay thế các ký hiệu không tất định trong cấu trúc cây lồng nhau của regex bằng một khoảng trắng.

Các thiết lập đánh giá TriviaQA Cộng đồng QA miền mở thường sử dụng các tập dữ liệu phát triển công khai làm tập dữ liệu kiểm thử, vì dữ liệu kiểm thử cho các tập dữ liệu QA thường bị hạn chế và dành riêng cho mục đích đọc hiểu. Chúng tôi báo cáo kết quả sử dụng cách chia tập dữ liệu được dùng trong DPR [26], nhất quán với thực hành phổ biến trong QA miền mở. Với TriviaQA, tập dữ liệu kiểm thử này là tập TriviaQA Web Development công khai. Roberts và cộng sự [52] thay vào đó sử dụng tập kiểm thử Wikipedia chính thức của TriviaQA. Févry và cộng sự [14] tuân theo quy ước này để so sánh với Roberts và cộng sự [52] (xem phụ lục của [14]). Chúng tôi báo cáo kết quả trên cả hai tập kiểm thử để cho phép so sánh công bằng với cả hai cách tiếp cận. Chúng tôi nhận thấy hiệu năng của mình cao hơn nhiều khi sử dụng tập kiểm thử Wiki chính thức so với tập kiểm thử miền mở thông thường hơn, điều mà chúng tôi cho là do các câu hỏi trong tập kiểm thử Wiki chính thức dễ trả lời hơn từ Wikipedia.

E Chi tiết bổ sung về FEVER

Với phân loại FEVER, chúng tôi làm theo cách làm từ [32]: trước tiên sinh lại khẳng định, sau đó phân loại dựa trên biểu diễn của trạng thái ẩn cuối cùng, trước khi cuối cùng lấy biên trên các tài liệu

[2] `https://github.com/pytorch/fairseq`
[3] `https://github.com/huggingface/transformers`

Bảng 7: Số lượng mẫu trong các tập dữ liệu được sử dụng. *Một tập con ẩn của dữ liệu này được dùng để đánh giá.

Tác vụ	Huấn luyện	Phát triển	Kiểm thử
Natural Questions	79169	8758	3611
TriviaQA	78786	8838	11314
WebQuestions	3418	362	2033
CuratedTrec	635	134	635
Sinh câu hỏi Jeopardy	97392	13714	26849
MS-MARCO	153726	12468	101093*
FEVER-3 lớp	145450	10000	10000
FEVER-2 lớp	96966	6666	6666

để thu được xác suất của các lớp. Tác vụ FEVER theo truyền thống có hai tác vụ con. Tác vụ thứ nhất là phân loại khẳng định thành "Được ủng hộ" (Supported), "Bị bác bỏ" (Refuted) hoặc "Không đủ thông tin" (Not Enough Info), đây là tác vụ mà chúng tôi khám phá trong bài báo chính. Tác vụ con còn lại của FEVER liên quan đến việc trích xuất các câu từ Wikipedia làm bằng chứng hỗ trợ cho dự đoán phân loại. Vì FEVER sử dụng một bản kết xuất Wikipedia khác với chúng tôi, việc giải quyết trực tiếp tác vụ này không đơn giản. Chúng tôi hy vọng sẽ giải quyết vấn đề này trong công trình tương lai.

F Xác suất của tài liệu rỗng

Chúng tôi đã thử nghiệm việc bổ sung cơ chế "tài liệu rỗng" (Null document) vào RAG, tương tự như REALM [20], nhằm mô hình hoá các trường hợp không thể truy xuất được thông tin hữu ích nào cho một đầu vào cho trước. Cụ thể, nếu k tài liệu được truy xuất, chúng tôi sẽ "truy xuất" thêm một tài liệu rỗng và dự đoán một logit cho tài liệu rỗng này, trước khi lấy biên trên $k + 1$ dự đoán. Chúng tôi đã khám phá việc mô hình hoá logit của tài liệu rỗng bằng cách học (i) một vectơ nhúng tài liệu cho tài liệu rỗng, (ii) một hệ số điều chỉnh (bias) tĩnh được học, hoặc (iii) một mạng nơ-ron để dự đoán logit. Chúng tôi không thấy các cách này cải thiện hiệu năng, vì vậy, để đơn giản, chúng tôi lược bỏ chúng. Với Open MS-MARCO, nơi không phải lúc nào cũng truy xuất được các tài liệu hữu ích, chúng tôi quan sát thấy mô hình học cách luôn truy xuất một tập tài liệu cụ thể cho những câu hỏi ít có khả năng hưởng lợi từ truy xuất, gợi ý rằng các cơ chế tài liệu rỗng có thể không cần thiết cho RAG.

G Tham số

Các mô hình RAG của chúng tôi chứa các tham số có thể huấn luyện của bộ mã hoá truy vấn và bộ mã hoá tài liệu BERT-base của DPR, mỗi bộ có 110 triệu tham số (mặc dù chúng tôi không tự huấn luyện bộ mã hoá tài liệu), và 406 triệu tham số có thể huấn luyện từ BART-large, 406 triệu tham số, tổng cộng là 626 triệu tham số có thể huấn luyện. Mô hình QA miền mở "sách đóng" (chỉ tham số) có hiệu năng tốt nhất là T5-11B với 11 tỷ tham số có thể huấn luyện. Mô hình T5 có số lượng tham số gần nhất với các mô hình của chúng tôi là T5-large (770 triệu tham số), đạt điểm 28.9 EM trên Natural Questions [52], thấp hơn đáng kể so với 44.5 mà RAG-Sequence đạt được, cho thấy các mô hình lai tham số/phi tham số cần ít tham số có thể huấn luyện hơn nhiều để đạt hiệu năng QA miền mở mạnh. Chỉ mục bộ nhớ phi tham số không bao gồm các tham số có thể huấn luyện, nhưng bao gồm 21 triệu vectơ 728 chiều, tương đương 15.3 tỷ giá trị. Các giá trị này có thể dễ dàng được lưu trữ ở độ chính xác dấu phẩy động 8-bit để kiểm soát dung lượng bộ nhớ và ổ đĩa.

H Sụp đổ truy xuất

Trong các thí nghiệm sơ bộ, chúng tôi quan sát thấy với một số tác vụ như sinh truyện [11], thành phần truy xuất sẽ "sụp đổ" (collapse) và học cách truy xuất cùng những tài liệu giống nhau bất kể đầu vào là gì. Trong những trường hợp này, một khi truy xuất đã sụp đổ, bộ sinh sẽ học cách bỏ qua các tài liệu, và mô hình RAG sẽ hoạt động tương đương với BART. Sự sụp đổ này có thể là do một số tác vụ có yêu cầu ít tường minh hơn về tri thức sự thật, hoặc do các chuỗi đích dài hơn, điều có thể dẫn đến gradient ít mang thông tin hơn cho bộ truy xuất. Perez và cộng sự [46] cũng phát hiện các kết quả truy xuất giả tạo (spurious) khi tối ưu hoá một thành phần truy xuất nhằm cải thiện hiệu năng trên các tác vụ hạ nguồn.

I Số lượng mẫu của mỗi tập dữ liệu

Số lượng điểm dữ liệu huấn luyện, phát triển và kiểm thử trong mỗi tập dữ liệu của chúng tôi được trình bày trong Bảng 7.

Phụ lục của người dịch: Bảng đối chiếu thuật ngữ Anh – Việt

Tiếng Anh	Tiếng Việt trong bản dịch
Retrieval-Augmented Generation (RAG)	Sinh văn bản tăng cường truy xuất
Knowledge-intensive tasks	Tác vụ đòi hỏi nhiều tri thức
Parametric / non-parametric memory	Bộ nhớ tham số / phi tham số
Pre-trained; fine-tune	Được huấn luyện trước; tinh chỉnh
Retriever; generator	Bộ truy xuất; bộ sinh
Query encoder; document index	Bộ mã hoá truy vấn; chỉ mục tài liệu
Bi-encoder; cross-encoder	Bộ mã hoá kép; bộ mã hoá chéo
Dense vector index	Chỉ mục vectơ dày đặc
Maximum Inner Product Search (MIPS)	Tìm kiếm tích vô hướng cực đại
Latent variable; marginalize	Biến ẩn; lấy biên
Prior / posterior	Xác suất tiên nghiệm / phân phối hậu nghiệm
Negative marginal log-likelihood	Log-hợp lý biên âm
Beam search; greedy decoding	Tìm kiếm chùm; giải mã tham lam
Thorough / Fast Decoding	Giải mã Kỹ lưỡng / Giải mã Nhanh
Open-domain QA; closed-book QA	Hỏi đáp miền mở; QA sách đóng
Extractive / abstractive QA	QA trích xuất / QA trừu tượng
Gold passage / evidence	Đoạn văn / bằng chứng chuẩn
Fact verification; claim	Kiểm chứng sự thật; khẳng định
Supports / refutes / not enough info	Ủng hộ / bác bỏ / không đủ thông tin
Factuality; specificity	Tính xác thực; tính cụ thể
Hallucination	Ảo giác
Exact Match (EM); label accuracy	Khớp chính xác; độ chính xác nhãn
Ablation; frozen retriever	Thí nghiệm cắt bỏ; bộ truy xuất đóng băng
Index hot-swapping	Hoán đổi nóng chỉ mục
Retrieval collapse	Sụp đổ truy xuất
Null document	Tài liệu rỗng
Downstream task; baseline	Tác vụ hạ nguồn; mô hình cơ sở
State of the art (SotA)	Tiên tiến nhất